

Automatic Grading TBS Hasil Panen Kelapa Sawit

Menggunakan AI Computer Vision untuk membantu klasifikasi kualitas TBS secara lebih konsisten, terdokumentasi, dan terintegrasi dengan proses panen.



Matang



Mentah



Lewat matang / busuk



Abnormal

Dari proses manual → data kualitas panen yang lebih objektif

Alur Pembahasan

Ringkasan logika masalah dan alasan project automatic grading dibutuhkan.

01

Kondisi proses panen saat ini

Pencatatan panen sudah mobile, tetapi grading kualitas masih manual.

02

Kelemahan proses grading manual

Data buah tidak sesuai kriteria masih berisiko tidak tercatat.

03

Dampak operasional lapangan

Sulit menganalisis pola pemanen, rotasi blok, abnormalitas, dan hama.

04

Dampak terhadap pengolahan CPO

Kualitas bahan baku TBS memengaruhi kualitas output pabrik.


05

Peluang solusi AI Computer Vision

Klasifikasi TBS otomatis sebagai data pendukung keputusan.

Kondisi Saat Ini

Pencatatan panen sudah terdigitalisasi, tetapi validasi kualitas TBS masih bergantung pada pemeriksaan manual.



Titik masalah utama

Proses grading manual masih menjadi celah karena hasil klasifikasi bergantung pada ketelitian manusia, kondisi lapangan, volume pekerjaan, dan konsistensi antar petugas.

Konsekuensi awal

Sebagian buah yang tidak sesuai kriteria dapat tidak teridentifikasi atau tidak tercatat lengkap sebagai data kualitas panen.

Masalah Utama: Grading Manual Tidak Konsisten


Manual grading menghasilkan data kualitas panen yang berpotensi tidak lengkap dan sulit diaudit.

Tidak semua buah terklasifikasi
Buah mentah, lewat matang/busuk, abnormal, atau dimakan tikus dapat terlewat.

Data tidak seragam
Penilaian sangat bergantung pada pengalaman dan kondisi petugas di lapangan.

Sulit ditelusuri
Saat data kualitas tidak lengkap, akar masalah sulit dianalisis secara objektif.

Rantai Dampak



Masalah bukan hanya pada denda pemanen, tetapi juga pada kualitas data operasional untuk pengambilan keputusan.

Kategori Grading yang Perlu Dideteksi

Setiap kategori memiliki makna operasional yang berbeda dan perlu dicatat sebagai data analitik.

Kategori	Makna Grading	Manfaat Data untuk Keputusan
Buah matang	Buah sesuai kriteria panen	Menjadi target panen yang diharapkan
Buah mentah	Buah belum layak panen	Analisa pemanen yang sering memanen buah mentah
Lewat matang / busuk	Buah terlambat dipanen	Evaluasi rotasi panen di blok tersebut
Buah abnormal	Buah tidak normal secara bentuk/kualitas	Mitigasi perbaikan parthenocarp
Dimakan tikus	Kerusakan akibat hama	Tindakan pengendalian hama tikus

Catatan: kategori “buah tidak sesuai kriteria” tidak hanya berhubungan dengan penalti, tetapi juga menjadi sinyal perbaikan proses panen, rotasi, dan pengendalian hama.

Dampak di Lapangan Bila Data Grading Tidak Lengkap

Data yang tidak tercatat mengurangi kemampuan organisasi untuk menganalisis masalah operasional secara objektif.

Buah Mentah

Sulit mengidentifikasi pemanen yang sering memanen buah belum layak panen.

Lewat Masak / Busuk

Evaluasi rotasi panen di blok menjadi kurang akurat.

Buah Abnormal

Peluang mitigasi masalah parthenocarp menjadi terlambat.


Dimakan Tikus

Respons pengendalian hama tikus dapat terlambat karena bukti lapangan tidak lengkap.

Akibatnya, proses improvement di lapangan lebih sering reaktif, bukan berbasis data kualitas panen yang lengkap.

Dampak ke Proses Pabrik dan Kualitas CPO

Kualitas TBS yang masuk ke pabrik sangat dipengaruhi oleh disiplin panen dan akurasi grading di lapangan.




Masalah kualitas bukan hanya muncul di pabrik
Sumber masalah dapat dimulai sejak keputusan panen di blok dan proses grading di lapangan.

Kualitas data menjadi kunci
Jika kategori buah tidak tercatat, pabrik hanya menerima dampaknya tanpa informasi penyebab yang lengkap.

Dengan grading otomatis, data lapangan dapat menjadi early warning untuk menjaga kualitas bahan baku sebelum masuk proses pengolahan.

Peluang Solusi: AI Computer Vision untuk Automatic Grading

AI digunakan sebagai alat bantu klasifikasi visual agar proses grading lebih konsisten dan terdokumentasi.



Perubahan yang diharapkan

- Manual dan subjektif → **Lebih objektif dan konsisten**
- Tidak semua kasus tercatat → **Kategori buah terdokumentasi**
- Analisa reaktif → **Analisa berbasis data visual**
- Penalti sulit diaudit → **Evidence foto + hasil klasifikasi**



Tujuan Project

Membangun fondasi automatic grading TBS sebagai penguatan kualitas data panen dan bahan baku pabrik.

Klasifikasi otomatis

Mendeteksi kategori TBS: matang, mentah, lewat matang/busuk, abnormal, dan dimakan tikus.

Evidence visual

Menyimpan foto sebagai bukti pendukung grading dan evaluasi pemanen.

Analitik lapangan

Membantu identifikasi pola pemanen, rotasi panen, abnormalitas buah, dan serangan hama.

Kontrol kualitas CPO

Meningkatkan kualitas input TBS agar proses pengolahan pabrik memiliki bahan baku yang lebih terkendali.

Kesimpulan

Project ini bukan hanya otomasi klasifikasi buah, tetapi juga upaya membangun data kualitas panen yang lebih objektif, sehingga keputusan operasional di lapangan dan kualitas bahan baku pabrik dapat dikendalikan lebih baik.

Data Collection

Dataset TBS kelapa sawit bersumber dari Roboflow dalam format YOLOv8.



Sumber Dataset

Roboflow: workspace "unsupervise-mharvesting"
Project: palm-oil-fg85a-vi4l8
Format: YOLOv8 (Ultralytics)



5 Kelas Klasifikasi


mentah (Unripe)
kurang_masak (Underripe) | masak (Ripe)
terlalu_masak (Overripe) | null (Background)



Split Dataset

Train: ~4.962 gambar | Valid: ~1.403 gambar
Test: ~700 gambar
Total objek: ~13.318 bounding box

Alur Data Ingestion



Distribusi Dataset per Split

Split	Gambar	Objek	Background	Label Kosong
Train	4.962	9.305	336	6.8%
Valid	1.403	2.655	92	6.6%
Test	700	1.358	45	6.4%
Total	7.065	13.318	473	6.7%

Dataset diunduh via Roboflow API dengan format YOLOv8. Setiap gambar memiliki anotasi bounding box untuk setiap kelas TBS yang terdeteksi.

Exploratory Data Analysis (EDA)

Validasi kualitas dataset dan analisis distribusi sebelum training.

✓ Duplicate Detection

Pengecekan gambar duplikat menggunakan MD5 hash per split (train/valid/test)


🛡️ Corrupt File Check

Validasi integritas file gambar (JPG/PNG). Hasil:
0 corrupt images di seluruh dataset

📊 Class Distribution

Analisis distribusi 4 kelas per split. Visualisasi bounding box: posisi center, luas, jumlah objek

Distribusi Kelas per Split




Temuan EDA


- ✓ Dataset bersih: 0 gambar corrupt
- ✓ Distribusi kelas seimbang antar split
- ✓ Anotasi bounding box terverifikasi konsisten
- ✓ Background images ~6.7% (label kosong)
- ✓ Format YOLOv8 kompatibel penuh
- ➔ Dataset siap untuk training model

EDA memastikan data berkualitas tinggi sebelum proses training, mengurangi risiko overfitting dan meningkatkan akurasi model final.

Visualisasi Distribusi Kelas




Anotasi Bounding Box




YOLOv8n Model Architecture

Versi Nano untuk keseimbangan optimal kecepatan dan akurasi di edge device.



Arsitektur YOLOv8n



Mengapa YOLOv8n?

- **Ukuran minimal:** Hanya ~6MB, ideal untuk mobile storage terbatas
- **Kecepatan tinggi:** Inferensi ~0.5ms/image di GPU, real-time capable
- **Akurasi kompetitif:** mAP50-95 0.766 pada dataset TBS
- **Edge optimized:** Dukungan ekspor TFLite, CoreML, ONNX
- **Pre-trained COCO:** Transfer learning mempercepat convergence

Format Ekspor yang Didukung

Format	Platform	Ukuran
PyTorch (.pt)	Training/Research	~6.2 MB
ONNX	Cross-platform	~12 MB
TFLite (FP16)	Android	~6 MB
TFLite (INT8)	Android (NPU)	~3 MB
CoreML	iOS (ANE)	~6 MB

Hyperparameter Tuning dengan Optuna

Framework Optuna dengan TPE Sampler untuk optimasi parameter training.

**Optimizer Dibandingkan**
SGD, Adam, AdamW, MuSGD — masing-masing 20 epoch tuning

**Scoring Objective**
Weighted: 70% mAP50-95 + 30% validation loss normalization

**Pruner & Sampler**
Median Pruner + TPE Sampler untuk efisiensi eksplorasi ruang parameter


Best Hyperparameters (Historis)

Parameter	Nilai	Keterangan
Optimizer	SGD / MuSGD	Terbaik
lr0 (initial LR)	0.00419	Learning rate
lrf (final LR)	0.02649	LR factor
weight_decay	0.00154	Regularisasi
momentum	0.91376	SGD momentum
batch	8	Batch size
imgsz	512	Input size

Augmentasi

mosaic: **0.771** | mixup: **0.148** | auto_augment: randaugment

Alur Hyperparameter Tuning






Manfaat Optuna Tuning:

- Menemukan LR optimal secara otomatis
- Membandingkan optimizer secara objektif
- Mengurangi trial-and-error manual

Hasil Hyperparameter Tuning dengan Optuna

Ringkasan Evaluasi Optimizer

	optimizer	status	best_epoch	best_precision	best_recall	best_map50	best_map50_95	best_val_loss	objective_score	elapsed_s	run_dir	error
0	SGD	ok	20	0.90006	0.93418	0.96327	0.75326	2.27206	0.390958	360.53	/home/ridwan/Documents/Final_Project/Grading_T...	
1	Adam	ok	20	0.88275	0.89713	0.94619	0.73101	2.36673	0.369703	369.98	/home/ridwan/Documents/Final_Project/Grading_T...	
2	AdamW	ok	20	0.86906	0.93114	0.95619	0.73970	2.32711	0.378163	371.80	/home/ridwan/Documents/Final_Project/Grading_T...	
3	MuSGD	ok	20	0.92168	0.93007	0.96899	0.76267	2.25614	0.398501	417.04	/home/ridwan/Documents/Final_Project/Grading_T...	



Model Training

Training final 50 epoch dengan hyperparameter optimal dari Optuna.

50

Epochs

17.4m

Training Time

RTX 5070 Ti

GPU (CUDA)

6.2MB

Model Output

Konfigurasi Training

Parameter	Nilai
Optimizer	MuSGD
Learning Rate (lr0)	0.00419
LR Factor (lrf)	0.02649
Batch Size	8
Image Size	512
Augmentasi	mosaic 0.771, mixup 0.148


Training Process

1. Load pretrained YOLOv8n (COCO weights)
 2. Apply best hyperparameters dari Optuna
 3. Training 50 epoch dengan augmentasi aktif
 4. Validasi per epoch pada data validasi
 5. Save best model (highest mAP50-95)
 6. Save last model (final epoch)
- Early stopping: patience=100 (tidak ter-trigger)
- Model konvergen stabil pada epoch 45-50

Hasil Training:

- Final mAP50-95 (validasi): **0.775**
- Precision: **0.947** | Recall: **0.943**
- Model output: best.pt + last.pt (~6.2 MB each)

Ringkasan Dataset




Kurva Training

Laporan Evaluasi Model

Tabel Nilai Terbaik dari Training

run	best_epoch	precision	recall	map50	map50_95	train_box_loss	val_box_loss	val_cls_loss	val_dfl_loss
palm_oil_optimized-2	50	94.68%	94.29%	97.91%	77.55%	0.705720	0.809150	0.391340	1.000920

Tabel nilai terbaik tersimpan di: docs/assets/grading_tph_best_epoch_summary.csv



Model Evaluation

Evaluasi komprehensif pada data test dan validasi.

0.975

mAP50 (Test)

0.766

mAP50-95 (Test)

0.931

Precision (Test)

0.946

Recall (Test)

325

FPS (imgsz=640)

Metrik per Kelas (Data Test)

Kelas	Precision	Recall	mAP50	mAP50-95
kurang_masak	0.936	0.896	0.960	0.719
masak	0.965	0.963	0.991	0.842
mentah	0.886	0.972	0.968	0.741
terlalu_masak	0.938	0.954	0.983	0.761

Insight Evaluasi

→ Kelas **masak** memiliki akurasi tertinggi (mAP50-95: 0.842)

→ Kelas **kurang_masak** paling challenging (mAP50-95: 0.719)

→ Precision > 0.88 untuk semua kelas




→ Recall > 0.89 untuk semua kelas

→ Inference < 0.5ms/image (GPU)


Validasi vs Test

Metrik	Validasi	Test	Selisih
mAP50-95	0.764	0.766	+0.002
mAP50	0.971	0.975	+0.004

Metrik Validasi vs Test , Model Per Kelas dan Confusion Matrix



Contoh Prediksi Model pada Data Validasi



Mobile Deployment

Ekspor model ke format mobile-optimized untuk deployment di lapangan.

Android (TFLite)

TFLite dengan kuantisasi FP16/INT8 untuk
NPU/GPU mobile Android


Kuantisasi INT8

Ukuran ~75% lebih kecil, inferensi lebih cepat di
mobile NPU

Pipeline Ekspor Model



Ukuran Model per Format



Deployment Strategy

- 1. Target Platform:** Android (TFLite)
 - 2. Format utama:** TFLite INT8 untuk ukuran minimal
 - 3. Hardware:** NPU/GPU mobile
 - 4. Input size:** 512x512 (training) → 640 (inference)
 - 5. Confidence threshold:** 0.25 (default)
- Gradio/ Hugging Face demo tersedia untuk testing
- Integration path: TFLite → mobile app

Kesimpulan & Next Steps

Hasil Pengembangan Model

- ✓ Model YOLOv8n berhasil ditrain dengan **mAP50-95: 0.766**
- ✓ Optuna tuning meningkatkan efisiensi dan akurasi
- ✓ Model ~6MB, siap untuk mobile deployment
- ✓ Format TFLite INT8: ~3MB untuk Android NPU
- ✓ Inference < 0.5ms/image (GPU), ~3ms (mobile)

Next Steps

1. Field testing di lokasi panen aktual
2. Continuous improvement dari feedback lapangan
3. Deployment production ke perangkat pemanen

0.766

mAP50-95

~3MB

TFLite INT8

325

FPS

Model siap untuk integrasi ke aplikasi mobile grading TBS

End-to-End Pipeline



Pipeline lengkap dari pengumpulan data hingga model siap berjalan di perangkat mobile di lapangan

Demo Mobile



Demo Website

Grading TBS Live Dashboard - Google Chrome

nuts-matched-themselves-limiting.trycloudflare.com

Apps | News | Imported From... | Imported From... | android | Imported From... | Imported From... | Working with the... | how to covert im... | Android Studio 2... | IlmuKomputer.C... | bcon | Udacity | All Bookmarks

Kontrol Inferensi

Path model best.pt

Confidence0.25

IoU0.45

Image size512

Max detections30

Mode input kamera

Snapshot / upload fallback

Server/IP camera continuous

WebRTC live camera

Mode public proxy aktif: gunakan Snapshot / upload fallback untuk demo publik paling stabil. WebRTC live camera butuh TURN relay agar stabil lewat Cloudflare/VPN.

Auto-save detections

Save interval seconds7.00

Ambil snapshot dari kamera

Clear photo

Atau upload gambar TBS

Upload

200MB per file • JPG, PNG

Kurang Masak (Underripe) 0.73

Kurang Masak (Underripe) 0.87

Kurang Masak (Underripe) 0.84

Device: CUDA:0

Session:
/home/ridwan/Documents/Final_Project/Grading_TPH/runs/streamlit_live_detection/session_20260619_085504

Status: Snapshot tersimpan: det_00001

Deteksi frame terakhir: 4

Inference terakhir: 53.3 ms

Download detections.csv

Kurang Masak (Underripe) 0.73

Kurang Masak (Underripe) 0.87

Kurang Masak (Underripe) 0.84

Kurang Masak (Underripe) 0.90

Event terbaru tersimpan

Demo Website

Grading TBS Live Dashboard

nuts-matched-themselves-limiting.trycloudflare.com

Apps | News | Imported From... | Imported From... | android | Imported From... | Imported From... | Working with the... | how to covert im... | Android Studio 2... | IlmuKomputer.C... | bcon | Udacity | All Bookmarks

Kontrol Inferensi

Path model best.pt

Confidence0.25

IoU0.45

Image size512

Max detections30

Mode input kamera

Snapshot / upload fallback

Server/IP camera continuous

WebRTC live camera

Mode public proxy aktif: gunakan Snapshot / upload fallback untuk demo publik paling stabil. WebRTC live camera butuh TURN relay agar stabil lewat Cloudflare/VPN.

Auto-save detections

Save interval seconds2.00

Auto-refresh dashboard

Refresh cascade

Audit Detail Event

Pilih event untuk audit

det_00001



Annotated image: det_00001

Lihat raw image

Metadata Event

```
{  "timestamp": "2026-06-19 09:31:31"  "total_detections": 4  "dominant_class": "Kurang Masak (Underripe)"  "top_confidence": 0.9006  "class_distribution": "Kurang Masak (Underripe): 4"  "inference_ms": 53.29  "estimated_fps": 18.76  "device": "CUDA:0"}
```


Download Annotation JSON

Download YOLO Labels TXT

Detail Bounding Box

class_id	class_name	confidence	x1	y1	x2	y2
0	Kurang Masak (Underripe)	0.9006	268.01	266	478.66	464
0	Kurang Masak (Underripe)	0.8695	298.79	77.69	483.93	270.67
0	Kurang Masak (Underripe)	0.8375	188.41	173.75	319.68	363.33
0	Kurang Masak (Underripe)	0.7329	188.96	0	317.28	188.94

Demo Dashboard



Kontrol Inferensi

Path model best.pt

Confidence

0.25

IoU

0.45

Image size

512

Max detections

30

Mode input kamera

- ☐ Snapshot / upload fallback
- ☐ Server/IP camera continuous
- ☒ WebRTC live camera

Mode public proxy aktif: gunakan Snapshot / upload fallback untuk demo publik paling stabil. WebRTC live camera butuh TURN relay agar stabil lewat Cloudflare/VPN.

☒ Auto-save detections

Save interval seconds

2.00


☐ Auto-refresh dashboard

Live Camera Detection

Izinkan akses Kamera dari browser. Bounding box tampil langsung pada video stream.

Catatan: WebRTC/camera browser biasanya hanya berjalan stabil di localhost atau HTTPS. Jika dashboard dibuka lewat tunnel publik, VPN, atau jaringan NAT ketat, koneksi live sering butuh TURN relay. Jika tombol Start tidak tersambung, gunakan mode Snapshot / upload fallback atau set konfigurasi TURN.

WebRTC ICE: TURN/STUN aktif. Mode live punya peluang lebih stabil dari jaringan publik.



STOP

Status Backend Lokal

Model: /home/ridwan/Documents/Final_Project/Grading_TPH/Huggingface/models/best.pt

Device: CUDA:0

Session:


/home/ridwan/Documents/Final_Project/Grading_TPH/runs/streamlit_live_detection/session_20260619_085504

Status: Snapshot tersimpan: det_00001

Deteksi frame terakhir: 4

Inference terakhir: 53.3 ms

Download detections.csv



Event terbaru tersimpan